

# Convolutional Neural Networks (CNNs)

---

Convolutional Neural Networks (CNNs)

---

# Introducción

## Motivación

¿Es posible hacer que las redes neuronales sean capaces **ver**?


Propiedades necesarias:

- 1 **Localidad**
- 2 **Invarianza al movimiento**
- 3 **Composición jerárquica**

# Introducción

Propiedades necesarias:



- 1 **Localidad:** Fijarse en zonas concretas. Elementos cercanos están relacionados.
- 2 **Invarianza al movimiento**
- 3 **Composición jerárquica**



# Introducción

Propiedades necesarias:


- 1 **Localidad:** Fijarse en zonas concretas. Elementos cercanos están relacionados.
- 2 **Invarianza al movimiento:** Misma salida si la posición del objeto de entrada cambia.
- 3 **Composición jerárquica**



# Introducción

Propiedades necesarias:

- 1 **Localidad:** Fijarse en zonas concretas. Elementos cercanos están relacionados.
- 2 **Invarianza al movimiento:** Misma salida si la posición del objeto de entrada cambia.
- 3 **Composición jerárquica:** Detectar patrones que definen un objeto.



## ¿Cómo funciona nuestra visión?

En 1981, David Hubel y Torsten Wiesel reciben el Nobel de medicina por sus contribuciones en el campo de la neurociencia y su investigación sobre el procesamiento visual en el cerebro.








## Convolutional networks

En 1990, LeCun entrena una red convolucional utilizando backpropagation. Aboga por el aprendizaje de características end-to-end en la clasificación de imágenes.



Convolutional Neural Networks (CNNs)

---

# Convoluciones


# Convoluciones

## Codificación de imágenes

Las imágenes son matrices de **pixels**. Cada uno posee un valor entre  $[0, 255]$  que representan la intensidad.

- Si la imagen es en blanco y negro, solo tendremos **una matriz**.
- Si es en color, tendremos **tres matrices**, una por cada **canal** (Rojo, Verde y Azul).

Imagen de 6x6 (B&N)



255	255	255	255	255	255
255	0	0	0	255	255
255	0	255	0	255	255
255	0	0	0	255	255
255	255	255	0	255	255
255	255	255	255	255	255


Imagen de 6x6 (RGB)




# Convoluciones

## Procesamiento dentro de una red

No pueden ser tratados como vectores “no estructurados” normales, han de ser invariantes al movimiento.




Además, los modelos resultantes tendrían un tamaño enorme:

- Una pequeña imagen en B&N de  $100 \times 100$  generaría un vector de 10000.

# Convoluciones

## Procesamiento dentro de una red

No pueden ser tratados como vectores “no estructurados” normales, han de ser invariantes al movimiento.



Además, los modelos resultantes tendrían un tamaño enorme:

- Una pequeña imagen en B&N de  $100 \times 100$  generaría un vector de 10000.

## Definición

Operación matemática capaz de extraer características o patrones de unos datos de entrada, típicamente imágenes o señales.

Compuesta por:

- Datos de entrada  $\mathbf{x}$ .
- Uno o varios **kernels** o filtros  $\mathbf{u}$ .
- Salida  $\mathbf{o}$ .

# Convoluciones: 1D




Si nuestros datos de entrada son de una dimensión (una señal, por ejemplo), tendremos que aplicar la **convolución 1D**.

Tendremos por tanto:

- Vector 1D de entrada  $\mathbf{x} \in \mathbb{R}^W$ .
- Vector 1D kernel  $\mathbf{u} \in \mathbb{R}^w$ .
- Vector 1D de salida  $\mathbf{o} \in \mathbb{R}^{W-w+1}$ .

La operación de convolución se define como:

$$(\mathbf{x} \circledast \mathbf{u})[i] = \sum_{m=0}^{w-1} x_{m+i} \cdot u_m$$



Utilizaremos el operador  $\circledast$  para referirnos a la convolución.

# Convoluciones: 1D



Si nuestros datos de entrada son de una dimensión (una señal, por ejemplo), tendremos que aplicar la **convolución 1D**.

Tendremos por tanto:

- Vector 1D de entrada  $\mathbf{x} \in \mathbb{R}^W$ .
- Vector 1D kernel  $\mathbf{u} \in \mathbb{R}^w$ .
- Vector 1D de salida  $\mathbf{o} \in \mathbb{R}^{W-w+1}$ .

La operación de convolución se define como:

$$(\mathbf{x} \circledast \mathbf{u})[i] = \sum_{m=0}^{w-1} x_{m+i} \cdot u_m$$



Utilizaremos el operador  $\circledast$  para referirnos a la convolución.



# Convoluciones: 1D




Si nuestros datos de entrada son de una dimensión (una señal, por ejemplo), tendremos que aplicar la **convolución 1D**.

Tendremos por tanto:

- Vector 1D de entrada  $\mathbf{x} \in \mathbb{R}^W$ .
- Vector 1D kernel  $\mathbf{u} \in \mathbb{R}^w$ .
- Vector 1D de salida  $\mathbf{o} \in \mathbb{R}^{W-w+1}$ .

La operación de convolución se define como:

$$(\mathbf{x} \circledast \mathbf{u})[i] = \sum_{m=0}^{w-1} x_{m+i} \cdot u_m$$



Utilizaremos el operador  $\circledast$  para referirnos a la convolución.

# Convoluciones: 1D




Si nuestros datos de entrada son de una dimensión (una señal, por ejemplo), tendremos que aplicar la **convolución 1D**.

Tendremos por tanto:

- Vector 1D de entrada  $\mathbf{x} \in \mathbb{R}^W$ .
- Vector 1D kernel  $\mathbf{u} \in \mathbb{R}^w$ .
- Vector 1D de salida  $\mathbf{o} \in \mathbb{R}^{W-w+1}$ .

La operación de convolución se define como:

$$(\mathbf{x} \circledast \mathbf{u})[i] = \sum_{m=0}^{w-1} x_{m+i} \cdot u_m$$



Utilizaremos el operador  $\circledast$  para referirnos a la convolución.

# Convoluciones: 1D



Si nuestros datos de entrada son de una dimensión (una señal, por ejemplo), tendremos que aplicar la **convolución 1D**.

Tendremos por tanto:

- Vector 1D de entrada  $\mathbf{x} \in \mathbb{R}^W$ .
- Vector 1D kernel  $\mathbf{u} \in \mathbb{R}^w$ .
- Vector 1D de salida  $\mathbf{o} \in \mathbb{R}^{W-w+1}$ .

La operación de convolución se define como:

$$(\mathbf{x} \circledast \mathbf{u})[i] = \sum_{m=0}^{w-1} x_{m+i} \cdot u_m$$



Utilizaremos el operador  $\circledast$  para referirnos a la convolución.

# Convoluciones: 1D



Si nuestros datos de entrada son de una dimensión (una señal, por ejemplo), tendremos que aplicar la **convolución 1D**.

Tendremos por tanto:

- Vector 1D de entrada  $\mathbf{x} \in \mathbb{R}^W$ .
- Vector 1D kernel  $\mathbf{u} \in \mathbb{R}^w$ .
- Vector 1D de salida  $\mathbf{o} \in \mathbb{R}^{W-w+1}$ .

La operación de convolución se define como:

$$(\mathbf{x} \circledast \mathbf{u})[i] = \sum_{m=0}^{w-1} x_{m+i} \cdot u_m$$



Utilizaremos el operador  $\circledast$  para referirnos a la convolución.

# Convoluciones: 1D




Si nuestros datos de entrada son de una dimensión (una señal, por ejemplo), tendremos que aplicar la **convolución 1D**.

Tendremos por tanto:

- Vector 1D de entrada  $\mathbf{x} \in \mathbb{R}^W$ .
- Vector 1D kernel  $\mathbf{u} \in \mathbb{R}^w$ .
- Vector 1D de salida  $\mathbf{o} \in \mathbb{R}^{W-w+1}$ .

La operación de convolución se define como:

$$(\mathbf{x} \circledast \mathbf{u})[i] = \sum_{m=0}^{w-1} x_{m+i} \cdot u_m$$



Utilizaremos el operador  $\circledast$  para referirnos a la convolución.

## 1 Lecture 5: Convolutional networks